Reconnaissance Optique de Musique

Livrable 2 : Rapport sur l'évaluation

Sacha Melin
Abdulkadir Kessaria

L'état de l'art étant établi, il faut maintenant définir des méthodes d'évaluation permettant de mesurer l'efficacité de la reconnaissance optique de musique. Le principe retenu est d'évaluer *séparément* chaque étape du processus : de cette manière, les goulots d'étranglement potentiels peuvent être repérés précisément, ce qui met en lumière les points d'attention de la pipeline.

Pour rappel, les étapes standard du processus, telles que décrites par Rebelo et al. [11], comprennent : prétraitement de l'image, reconnaissance des symboles, reconstruction de l'information musicale, et encodage de la notation. La maturité des métriques est inégale et les deux dernières étapes de la pipeline restent un problème de recherche ouvert sans métriques claires [8, 1]. L'ensemble des critères est synthétisé dans les tableaux regroupés en fin de document (Tableaux 1 à 4).

Prétraitement de l'image. Le prétraitement (lissage, binarisation, redressement) est facilement évaluable dès lors qu'on dispose d'une *source de vérité* : une image de référence permettant la comparaison. Sur données synthétiques ou typographiées, cette vérité terrain se génère gratuitement. Les critères associés sont détaillés au Tableau 1.

Reconnaissance des symboles. Cette phase se décompose en traitement de la portée, isolation des symboles et classification. La suppression de portées et l'isolation se comparent au pixel ou à la boîte englobante ; la classification est un problème multiclasse supervisé où la matrice de confusion est l'information la plus utile pour cibler les améliorations. Les critères associés sont détaillés au Tableau 2.

Reconstruction de l'information musicale. L'OMR étant un problème bidimensionnel, il faut identifier la séquence des symboles *et* leurs relations spatiales [14]. Cette étape porte donc sur les *relations* entre symboles (quelle altération s'applique à quelle tête de note, hampe-vers-tête, ligatures). L'approche moderne représente la partition comme un *graphe de notation* et évalue les arêtes. Le critère associé est détaillé au Tableau 3.

Encodage de la notation musicale (bout en bout). La dernière étape encode l'information dans un format expressif (MusicXML [5], MEI [13]). C'est ici que le domaine n'a *pas* de métrique prédéfinie : c'est un problème ouvert publié [8, 6, 15]. La difficulté centrale est de définir une distance d'édition entre deux représentations de partition. Les critères associés sont détaillés au Tableau 4.

Stratégie globale. Le plan retenu est d'évaluer chaque module avec sa métrique native - F-mesure DIBCO → F1 pixel de portée → mAP de détection → matrice de confusion / F1 de classification - puis d'ajouter *une* métrique de bout en bout (SER si la sortie est monophonique, TEDn si l'on cible MusicXML). L'évaluation par module localise où les erreurs apparaissent ; le score de bout en bout est ce qui se compare aux autres systèmes. L'emploi de partitions synthétiques/typographiées pour au moins une partie du jeu de test résout le problème de vérité terrain des étapes de prétraitement qui paraissent autrement "non mesurables".

Base d'évaluation. Nous avons décidé de nous concentrer sur les partitions *non manuscrites* (typographiées). Nous nous appuyons sur des bases publiques de référence, complétées par des partitions *synthétiques* générées par nos soins (vérité terrain parfaite et gratuite pour le prétraitement, la portée et le redressement via déformations contrôlées).

— **DeepScoresV2** [16] - partitions typographiées pour la détection d'objets ; ∼151 M instances, 135 classes. Vérité terrain au niveau boîte et segmentation.
Accès : `https://zenodo.org/records/4012193` - licence **CC BY 4.0**.

— **PrIMuS / Camera-PrIMuS** [2] - 87 678 *incipits* monophoniques typographiés, fournis en PNG, MIDI, MEI et deux encodages (sémantique et agnostique) ; idéal pour le SER de bout en bout. Camera-PrIMuS ajoute des distorsions simulant une photo.
Accès : `https://grfia.dlsi.ua.es/primus/` (téléchargement libre, citation requise).
— **DIBCO / H-DIBCO** [9] - images dégradées et vérités terrain binaires de référence, dédiées à l'évaluation de la binarisation.
Accès : `https://vc.ee.duth.gr/h-dibco2018/` (librement disponibles pour la recherche).

Tableaux récapitulatifs

Outil	Description	Score acceptable
F-mesure (pixel)	Moyenne harmonique de la précision et du rappel calculés sur les pixels d'encre, comparés à une image binaire de référence. Caractérise l'exactitude globale de la binarisation.	$\in [0,1]$, plus haut = mieux ; $> 0{,}90$ pour les bons systèmes DIBCO.
PSNR	$10\log_{10}(C^2/\mathrm{MSE})$ en décibels : proximité globale à la vérité terrain (C = amplitude max, MSE = erreur quadratique moyenne).	dB, plus haut = mieux ; $>$ 20 dB excellent, $\sim$ 12 dB médiocre.
DRD	*Distance Reciprocal Distortion* : erreurs pondérées par les distances réciproques sur un voisinage 5×5, normalisées par le nombre de blocs 8×8 non uniformes. Calée sur la perception visuelle humaine.	Distorsion, plus bas = mieux ; 0 = parfait, < 3 très bon.
Erreur angulaire	Angle résiduel $\lvert\hat{\theta}-\theta\rvert$ après correction d'une rotation synthétique d'angle connu θ. Caractérise la précision du redressement.	degrés, plus bas = mieux ; $< 0{,}5°$ excellent.

Tableau 1 : critères d'évaluation du prétraitement.

Outil	Description	Score acceptable
F1 pixel (portée) [3, 4]	Classification pixel par pixel "portée / hors-portée" : on compare le masque de portée prédit à la vérité terrain (précision, rappel, F1 sur la classe "portée").	$\in [0,1]$, plus haut = mieux ; $> 0{,}95$ sur imprimé propre.
P/R/F1 @IoU (isolation)	Détection d'objets : boîtes prédites appariées aux boîtes de vérité terrain via l'IoU à un seuil fixe (typ. 0,5).	$\in [0,1]$, plus haut = mieux.
mAP (isolation)	*mean Average Precision* : moyenne, sur les classes, de l'aire sous la courbe précision–rappel. Capacité à localiser *et* étiqueter.	$\in [0,1]$, 1 = détection idéale.
Exactitude (classification) [10]	Proportion de symboles isolés correctement étiquetés ; complétée par précision/rappel/F1 par classe.	$\in [0,1]$, $> 0{,}90$ sur symboles imprimés isolés.
Matrice de confusion (classification)	Tableau vérité terrain × prédiction : révèle *quelles* classes sont confondues (p. ex. silence de noire vs. de croche).	Diagonale forte, hors-diagonale faible.

Tableau 2 : critères d'évaluation de la reconnaissance des symboles.

Outil	Description	Score acceptable
P/R/F1 sur les arêtes [17]	On compare l'ensemble des arêtes (relations) du graphe prédit à celles de la vérité terrain ; une arête est correcte si la même relation relie les deux mêmes objets. En aval des erreurs de détection.	$\in [0,1]$, plus haut = mieux.

Tableau 3 : critère d'évaluation de la reconstruction.

Outil	Description	Score acceptable
SER [2]	*Symbol Error Rate* : distance d'édition (Levenshtein) sur une séquence linéarisée de symboles, normalisée par la longueur de la référence. Analogue du *Word Error Rate*.	≥ 0, plus bas = mieux ; 0 = parfait, 0,1 $\approx$ 1 symbole/10 à corriger.
Distance normalisée	Distance d'édition divisée par la longueur de la plus longue séquence.	$\in [0,1]$, plus bas = mieux.
TEDn [12]	*Tree Edit Distance* normalisée (Zhang–Shasha) adaptée aux arbres MusicXML/MEI ; corrèle avec l'effort de correction attendu par un éditeur humain (type MuseScore).	≥ 0, plus bas = mieux ; 0 = arbres identiques.

Tableau 4 : critères d'évaluation de l'encodage / bout en bout. La métrique OMR-NED [7] raffine SER avec un profilage par catégorie de symbole.

Références

[1] Donald Byrd and Jakob Grue Simonsen. Towards a standard testbed for optical music recognition : Definitions, metrics, and page images. *Journal of New Music Research*, 44(3) :169–195, 2015.

[2] Jorge Calvo-Zaragoza and David Rizo. End-to-end neural optical music recognition of monophonic scores. *Applied Sciences*, 8(4) :606, 2018.

[3] Christoph Dalitz, Michael Droettboom, Bastian Pranzas, and Ichiro Fujinaga. A comparative study of staff removal algorithms. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 30(5) :753–766, 2008.

[4] Alicia Fornés, Anjan Dutta, Albert Gordo, and Josep Lladós. The ICDAR/GREC 2013 music scores competition : Staff removal. In *Graphics Recognition. Current Trends and Challenges (GREC)*, 2013.

[5] M. Good. Musicxml for notation and analysis. *The Virtual Score : Representation, Retrieval, Restoration*, 12 :113–124, 2001.

[6] Jan Hajič jr., Jiří Novotný, Pavel Pecina, and Jaroslav Pokorný. Further steps towards a standard testbed for optical music recognition (a case for intrinsic evaluation). In *1st International Workshop on Reading Music Systems (WoRMS)*, 2018.

[7] Juan C. Martínez-Sevilla, Antonio Ríos-Vila, David Rizo, and Jorge Calvo-Zaragoza. Sheet music benchmark : Standardized optical music recognition evaluation. In *International Society for Music Information Retrieval Conference (ISMIR)*, 2025. Introduit la métrique OMR-NED.

[8] Luca Mengarelli, Bruno Kostiuk, Juliano G. Vitório, Mauro A. Tibola, William Wolff, and Carlos N. Silla. On the development of an automatic optical music recognition system : metrics and evaluation. *Multimedia Tools and Applications*, 79, 2019.

[9] Ioannis Pratikakis, Basilis Gatos, and Konstantinos Ntirogiannis. ICDAR 2011 document image binarization contest (DIBCO 2011). In *International Conference on Document Analysis and Recognition (ICDAR)*, pages 1506–1510, 2011.

[10] Ana Rebelo, G. Capela, and Jaime S. Cardoso. Optical recognition of music symbols : A comparative study. *International Journal on Document Analysis and Recognition*, 13(1) :19–31, 2010.

[11] Ana Rebelo, Ichiro Fujinaga, Filipe Paszkiewicz, Andre R. S. Marcal, Carlos Guedes, and Jaime S. Cardoso. Optical music recognition : state-of-the-art and open issues. *International Journal of Multimedia Information Retrieval*, 1(3) :173–190, 2012.

[12] Antonio Ríos-Vila, David Rizo, José M. Iñesta, and Jorge Calvo-Zaragoza. Practical end-to-end optical music recognition for pianoform music. In *International Conference on Document Analysis and Recognition (ICDAR)*, 2024. Introduit la métrique TEDn.

[13] P. Roland. The music encoding initiative (mei). In *1st International Conference on Musical Applications Using XML*, pages 55–59, 2002.

[14] Elona Shatri and György Fazekas. Optical music recognition : State of the art and major challenges. In *International Conference on Technologies for Music Notation and Representation (TENOR)*, 2020.

[15] Pau Torras, Sanket Biswas, and Alicia Fornés. A unified representation framework for the evaluation of optical music recognition systems. *arXiv preprint arXiv :2312.12908*, 2023.

[16] Lukas Tuggener, Yvan Putra Satyawan, Alexander Pacha, Jürgen Schmidhuber, and Thilo Stadelmann. The DeepScoresV2 dataset and benchmark for music object detection. In *25th International Conference on Pattern Recognition (ICPR)*, 2020.

[17] Guang Wang et al. Toward a more complete omr solution. *arXiv preprint arXiv :2409.00316*, 2024.