Reconnaissance Optique de Musique

Livrable 3 : Prototype et méthodes

Sacha Melin
Abdulkadir Kessaria

Ce livrable présente le prototype développé et les méthodes retenues pour chaque étape du processus de reconnaissance optique de musique (OMR), selon le découpage en quatre phases rappelé par Rebelo et al. [18] : prétraitement de l'image, reconnaissance des symboles, reconstruction de l'information musicale, et encodage de la notation. Le périmètre est volontairement restreint aux *noires et croches* : têtes de notes pleines, hampes et ligatures. Clés, altérations, armures, silences, crochets, têtes ouvertes (blanches, rondes) et notes d'ornement sont exclus des prédictions comme de la vérité terrain. Cette restriction, justifiée plus loin en Classification, découle des difficultés rencontrées sur un périmètre initialement plus large.

Prétraitement de l'image. La binarisation utilise le seuillage adaptatif local de Sauvola [21] (fenêtre 31×31, $k = 0{,}12$), la convention étant encre = 0 / fond = 255. Cette étape est parmi les plus faciles à évaluer car la vérité terrain se génère gratuitement sur données typographiées ; les métriques natives sont la F-mesure pixel, le PSNR et la DRD (Distance Reciprocal Distortion) au sens DIBCO [15, 13].

Le redressement repose sur l'estimation de l'angle d'inclinaison par transformée de Hough [2] sur les arêtes de Canny ; notons que sur le sous-ensemble DeepScoresV2 les images sont déjà redressées, l'estimation n'est donc pas appliquée dans la pipeline mais reste évaluée séparément par le benchmark dédié (erreur angulaire résiduelle).

Pour la détection des portées, nous avons d'abord prototypé et intégré une approche par plus court chemin, à la suite de Rebelo et al. [17] : on construit un graphe de pixels (8-connexité) puis on calcule, pour chaque ligne, le plus court chemin de gauche à droite via l'algorithme de Dijkstra [9] en pénalisant les pixels d'encre. La méthode est invariante aux portées non rectilignes mais s'est révélée lourde (graphe dense sur l'image entière) et peu efficace en pratique sur nos images ; nous l'avons remplacée par la méthode usuelle de profil de projection horizontale [4], qui recherche les maxima du nombre de pixels d'encre par ligne après binarisation.

Pour la suppression des lignes de portée, on parcourt ensuite les segments verticaux par colonne et l'on n'efface que les segments d'épaisseur inférieure à $2\times$ la hauteur de ligne, de sorte que les hampes traversant les lignes soient conservées ; les barres de mesure, quant à elles, sont retirées par un critère d'*envergure* (segments verticaux traversant tout le système de portée), les hampes n'atteignant jamais les deux extrémités.

Isolation des symboles. Une fois les portées supprimées, chaque composante connexe est décomposée en primitives par ouverture morphologique avec des éléments structurants adaptés [14], dans l'ordre :

- détection des *ligatures* par ouverture avec un segment pivoté ;
- détection des *hampes* par ouverture verticale avec une sonde étroite (choisie pour préserver les hampes fines des polices DeepScores), après soustraction de la ligature ;
- détection des *têtes pleines* par balayage d'un gabarit elliptique autour des extrémités de chaque hampe.

L'encre résiduelle devient une primitive `unknown`. Le statut d'une composante est `REJECTED` si la topologie est invalide (ce critère prime sur tout autre), `UNCERTAIN` si la topologie est valide mais qu'il reste de l'encre inexpliquée, `ACCEPTED` sinon (une tête par hampe, une ligature reliée à ≥ 2 hampes).

Classification. L'état de l'art [16, 18] recommande, pour la classification des symboles isolés, des descripteurs de forme (HOG [8], profils de projection) couplés à un classifieur statistique de type SVM ou k-NN, les SVM surpassant souvent les HMM sur cette tâche [16]. Une première étude a exploré cette voie sur un périmètre large (clés, altérations, bémols, têtes ouvertes, etc.). Cette voie s'est heurtée à deux obstacles : (1) la *fragmentation* des composantes connexes, c'est-à-dire que la suppression des lignes de portée fend les têtes ouvertes (blanches, rondes) en deux arcs et que les bémols ne sont pas séparables de manière fiable ; (2) l'instabilité des descripteurs sur ces fragments. Faute de reconstruction fiable des

composantes, nous avons fait marche arrière et réduit le périmètre aux noires et croches (têtes pleines), pour lesquelles la classification se ramène à un problème *géométrique* n'exigeant pas de classifieur entraîné.

La classification porte donc sur quatre catégories au sens de DeepScores : `noteheadBlackOnLine`, `noteheadBlackInSpace`, `stem`, `beam`. La distinction *OnLine/InSpace* est déterminée par la position verticale du centre de la tête par rapport aux lignes de portée détectées ; les hampes et ligatures héritent de leur étiquette selon le type de primitive morphologique. La *durée* est dérivée structurellement : tête pleine et hampe sans ligature → noire, têtes pleines jointes par une ligature → croches.

La *hauteur* est calculée à partir de la position verticale de la tête, exprimée en demi-interlignes au-dessus de la ligne inférieure de la portée, puis convertie en degré diatonique. La clé est supposée *sol*, une hypothèse acceptable grâce à la sélection de pages mono-clé dans le benchmark.

Reconstruction de l'information musicale. L'OMR étant un problème bidimensionnel [22], il faut retrouver la séquence des symboles *et* leurs relations spatiales. Nous modélisons la partition comme un *graphe de notation* et appliquons une approche par règles de réécriture, comme décrit par Fahmy et Blostein [10, 11, 3] et dans la lignée des grammaires EPF de Coüasnon [6, 7] et du moteur de construction de Bainbridge et Bell [1]. Trois règles de réécriture sont appliquées jusqu'à point fixe : (1) une hampe portant exactement une tête → `NOTE` ; (2) des notes partageant une même ligature → `BEAMED_GROUP`. Les accords (plusieurs têtes sur une hampe) ne sont pas intégrés à ce stade. Les relations `HEAD_TO_STEM` et `STEM_TO_BEAM` issues du découpage sont traduites en arêtes du graphe ; les relations spatiales `ABOVE` et `ALIGNED_VERTICAL` sont ajoutées par parcours des paires de nœuds. Cette approche par règles relève plus du *discrete relaxation* [11] que d'une grammaire formelle stricte : la sémantique musicale naît de motifs locaux réécrits itérativement, comme dans les approches par fusion de règles [20].

Encodage de la notation. La séquence de durées (jetons `quarter`/`eighth`) et la séquence de hauteurs (jetons diatoniques de type `A4`) sont émises dans l'ordre de lecture (tri par abscisse). La sortie MIDI est monophonique : chaque note est déclenchée puis relâchée une fois sa durée écoulée, sans chevauchement ni silence explicite. Cette étape reste limitée à la restitution sonore (hauteur, durée) ; les formats expressifs MusicXML [12] et MEI [19] ne sont pas pris en charge par le prototype, conformément à la hiérarchie de difficultés décrite par Calvo-Zaragoza et al. [5].

Références

[1] D. Bainbridge and T. Bell. A music notation construction engine for optical music recognition. *Software : Practice and Experience*, 33(2) :173–200, 2003.

[2] D.H. Ballard. Generalizing the hough transform to detect arbitrary shapes. *Pattern Recognition*, 13(2) :111–122, 1981.

[3] Dorothea Blostein. Issues in the practical use of graph rewriting. In *Graph Transformations and Their Application in Biology and Computer Science (LNCS 1073)*, pages 30–43. Springer, 1996.

[4] Dorothea Blostein and Henry S. Baird. *A Critical Survey of Music Image Analysis*, pages 405–434. Springer Berlin Heidelberg, Berlin, Heidelberg, 1992.

[5] Jorge Calvo-Zaragoza, Jan Hajič jr., and Alexander Pacha. Understanding optical music recognition. *ACM Computing Surveys*, 53(4) :1–35, 2020.

[6] B. Coüasnon, P. Brisset, and I. Stéphan. Using logic programming languages for optical music recognition. In *3rd International Conference on the Practical Application of Prolog*, pages 115–134, 1995.

[7] Bertrand Coüasnon. DMOS, a generic document recognition method : application to an automatic generation of musical scores. *International Journal on Document Analysis and Recognition*, 2(4), 2006.

[8] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893, 2005.

[9] E. W. Dijkstra. A note on two problems in connexion with graphs. *Numerische Mathematik*, 1(1) :269–271, 1959.

[10] Hoda Fahmy and Dorothea Blostein. A graph-grammar programming style for recognition of music notation. *Machine Vision and Applications*, 6(2) :83–99, 1993.

[11] Hoda Fahmy and Dorothea Blostein. A graph-rewriting paradigm for discrete relaxation : application to sheet-music recognition. *International Journal of Pattern Recognition and Artificial Intelligence*, 12(6) :763–799, 1998.

[12] M. Good. Musicxml for notation and analysis. *The virtual score : representation, retrieval, restoration*, 12 :113–124, 2001.

[13] Haiping Lu, Alex C. Kot, and Yun Q. Shi. Distance-reciprocal distortion measure for binary document images. *IEEE Signal Processing Letters*, 11(2) :228–231, 2004. DRD : Distance Reciprocal Distortion metric.

[14] K.C. Ng and R.D. Boyle. Recognition and reconstruction of primitives in music scores. *Image and Vision Computing*, 14(1) :39–46, 1996.

[15] Konstantinos Ntirogiannis, Basilis Gatos, and Ioannis Pratikakis. A combined approach for the document image binarization problem. *Pattern Recognition*, 46(1), 2013. DIBCO : Document Image Binarization Contest, ICDAR 2011.

[16] A. Rebelo, G. Capela, and J. d. S. Cardoso. Optical recognition of music symbols. *International Journal on Document Analysis and Recognition*, 13(1) :19–31, 2010.

[17] Ana Rebelo, Artur Capela, Joaquim F. Pinto da Costa, Carlos Guedes, Eurico Carrapatoso, and Jaime S. Cardoso. A shortest path approach for staff line detection. In *Third International Conference on Automated Production of Cross Media Content for Multi-Channel Distribution (AXMEDIS'07)*, pages 79–85, 2007.

[18] Ana Rebelo, Ichiro Fujinaga, Filipe Paszkiewicz, Andre R S Marcal, Carlos Guedes, and Jaime S Cardoso. Optical music recognition : state-of-the-art and open issues. *Int. J. Multimed. Inf. Retr.*, 1(3) :173–190, 2012.

[19] P. Roland. The music encoding initiative (mei). In *1st International Conference on Musical Applications Using XML*, pages 55–59, 2002.

[20] Florence Rossant and Isabelle Bloch. Robust and adaptive OMR system including fuzzy modeling, fusion of musical rules, and possible error detection. *EURASIP Journal on Advances in Signal Processing*, 2007, 2007.

[21] Jaakko Sauvola and Matti Pietikäinen. Adaptive document image binarization. *Pattern Recognition*, 33(2) :225–236, 2000.

[22] Elona Shatri and György Fazekas. Optical music recognition : State of the art and major challenges. In *International Conference on Technologies for Music Notation and Representation (TENOR)*, 2020.