Reconnaissance Optique de Musique

Livrable 4 : Rapport sur les résultats

Sacha Melin
Abdulkadir Kessaria

La stratégie d'évaluation, détaillée dans le Livrable 2, consiste à mesurer *séparément* chaque étape de la pipeline avec sa métrique native (F-mesure DIBCO → F1 pixel de portée → mAP de détection → matrice de confusion / F1 de classification → F1 sur les arêtes), puis à ajouter un score de bout en bout (SER). Nous ne rappelons ici que les valeurs obtenues ; les définitions des métriques et des seuils acceptables figurent dans le livrable précédent.

Base d'évaluation. Les mesures portent sur un sous-ensemble du jeu DeepScoresV2 [2], version *dense* (annotations au niveau instance et segmentation, ~ 1 Go en local). L'évaluation *par étapes* utilise la partition `test` sur 10 pages, le périmètre étant restreint aux quatre catégories prises en charge par la pipeline : `noteheadBlackOnLine`, `noteheadBlackInSpace`, `stem`, `beam`. Les autres classes (clés, altérations, silences, têtes ouvertes, crochets, notes d'ornement) sont exclues des prédictions *et* de la vérité terrain filtrée, ce qui évite d'annuler artificiellement le rappel sur les pages longues. Le seuil IoU d'appariement des boîtes est fixé à 0,3 par défaut (cf. limites plus bas).

Prétraitement (étape 1). Le benchmark de binarisation (paires d'images dégradées / vérité terrain binaire) obtient une F-mesure pixel moyenne de **0**,**8120**, un PSNR moyen de **14**,**47** dB et une DRD moyenne de **9**,**05**. Le benchmark de redressement (images à rotation synthétique d'angle connu) atteint une erreur angulaire moyenne de **0**,**28**ř, sous le seuil de tolérance de 0,5ř. Sur le sous-ensemble DeepScoresV2, les images sont typographiées et déjà droites ; le redressement n'y est donc pas appliqué, mais la binarisation Sauvola reste active.

Séparation des primitives (étape 5, masque). Le tableau 1 présente les P/R/F1/IoU par type de primitive, calculés au pixel sur les masques booléens et agrégés sur les 10 pages test.

Primitive	Précision	Rappel	F1	IoU
notehead	0,9210	0,9489	0,9339	0,9038
stem	0,7532	0,7853	0,7584	0,6705
beam	0,9098	0,8959	0,8936	0,8429
unknown	0,5117	0,4335	0,4371	0,3487

Tableau 1 : évaluation pixel des masques par primitive sur 10 pages test.

Détection et classification (étape 5, objet). Le tableau 2 donne la précision moyenne (mAP) et l'exactitude de classification sur les 1969 paires appariées au seuil IoU 0,3 sur 10 pages test. L'exactitude atteint 0,93 ; la grande majorité des erreurs est une confusion `noteheadBlackOnLine` → `noteheadBlackInSpace` (170 cas), due à la position verticale de la tête à proximité immédiate d'une ligne de portée, où le seuil entre « sur la ligne » et « entre les lignes » devient sensible au bruit de binarisation. Les autres classes (hampes, ligatures, `InSpace`) restent correctement étiquetées, la matrice de confusion est quasi diagonale (tableau 3).

Métrique	Valeur
mAP @IoU= 0,3	0,6445
AP `noteheadBlackOnLine`	0,7891
AP `noteheadBlackInSpace`	0,8372
AP `stem`	0,2243
AP `beam`	0,7274
Exactitude (classification)	0,9309

Tableau 2 : mAP et exactitude de classification sur 10 pages test.

Vérité ↓ / Prédiction →	OnLine	InSpace	stem	beam
`noteheadBlackOnLine`	**504**	170	0	1
`noteheadBlackInSpace`	0	**660**	0	3
`stem`	0	0	**363**	0
`beam`	0	0	0	**268**

Tableau 3 : matrice de confusion (somme sur 10 pages, 1969 paires). Lignes = vérité terrain, colonnes = prédiction.

Reconstruction (étape 6, arêtes). Les arêtes du graphe (`HEAD_TO_STEM`, `STEM_TO_BEAM`) sont comparées à la vérité terrain : précision 0,4026, rappel 0,3978, F1 0,4001. Les erreurs proviennent essentiellement de paires non appariées en amont : toute arête touchant une primitive non appariée est comptée comme faux positif, et toute arête manquante comme faux négatif.

Bout en bout (SER). La séquence de durées (jetons `quarter`/`eighth`) obtient un *Symbol Error Rate* [1] de **0,1105**, soit environ une erreur pour 10 symboles : la structure (noire vs. croche) est globalement respectée, mais pâtit des erreurs d'appariement en amont. Le SER sur les hauteurs vaut **0,3783**, soit près d'une erreur sur trois ; c'est le goulot d'étranglement de la pipeline. Il s'explique par la fragilité du calcul de hauteur : position verticale de la tête convertie en degré diatonique, clé supposée *sol* par défaut, ni armure ni altération. Une erreur d'une demi-interligne (un seul degré diatonique) suffit à produire un jeton de hauteur erroné.

Limites et artefact des classes fines. La principale limite de l'évaluation par objet est l'*artefact des classes fines* : DeepScores annote les hampes avec des boîtes de largeur 1 pixel, de sorte qu'une hampe correctement prédite mais un peu trop large ne passe pas le seuil IoU usuel. Entre les seuils 0,3 et 0,5, le mAP chute de 0,64 à 0,59 et le F1 des arêtes de 0,40 à 0,12. L'AP des hampes s'effondre (0,22 $\rightarrow$ 0,03) tandis que les classes larges (têtes de notes, ligatures) restent stables (AP $\geq$ 0,70).

Le seuil 0,3 retenu par défaut reflète donc mieux la qualité réelle de la détection sur les classes fines ; nous indiquons 0,5 à titre de référence stricte.

Le prototype présente d'autres limites :

— portée restreinte aux noires et croches ;
— clé codée en dur (sol) ;
— sortie MIDI monophonique, sans silence ;

Tests unitaires. La suite de tests comporte **89 tests, tous réussis**. Le tableau 4 détaille les modules.

Module	Périmètre	Tests	Statut
`test_splitting`	séparation morphologique (têtes/hampes/ligatures), statuts	6	OK
`test_assembly`	règles de réécriture du graphe (note, accord, groupe lié)	18	OK
`test_semantics`	durées (noire/croche/...), hauteurs, validation de mesure	9	OK
`test_deepscores_io`	annotations, arêtes, séquences durée/hauteur, vérité terrain	15	OK
`test_deepscores`	test de démarrage du chargeur de jeu de données	2	OK
`test_pipeline_metrics`	IoU, mAP, matrice de confusion, P/R/F1 sur les arêtes, SER	28	OK
`test_midi`	conversion jetons $\rightarrow$ MIDI (PPQ, hauteurs, durées)	11	OK
Total		**89**	**OK**

Tableau 4 : suite de tests par module (tous réussis).

Références

[1] Jorge Calvo-Zaragoza and David Rizo. End-to-end neural optical music recognition of monophonic scores. *Applied Sciences*, 8(4) :606, 2018.

[2] Lukas Tuggener, Yvan Putra Satyawan, Alexander Pacha, Jürgen Schmidhuber, and Thilo Stadelmann. The DeepScoresV2 dataset and benchmark for music object detection. In *25th International Conference on Pattern Recognition (ICPR)*, 2020.